

情景训练与智能问答 演练中心

提升方向十八 · 独立优化进度、演示与验收报告

以真实项目连续追问，让回答有证据、评分可复算、训练不污染正式业务。

数据库	全量回归	真实项目	批准题目
v58	564 / 564	4 个	24 道
5 张训练表	616 子测试	全部脱敏	六阶段量表

一、执行结论

提升方向十八已经从方案落成独立可运行模块。TenderTrace 现在可以把已有真实公告、需求、公告修订和证据快照转成脱敏训练场景，按“开场、基础事实、证据追问、风险变化、行动计划、总结”六个阶段连续提问。参训者可以选择准备模式或学习模式，系统保存首次回答、证据引用、追问、耗时、规则得分、模型建议状态和补强任务，并生成可复算的匿名回放。

当前生产数据中已建立 4 个已批准场景，覆盖 4 个真实项目和 4 类训练：七分钟脱稿答辩、技术标澄清、更正公告应急、合作方风险谈判。每个场景包含 6 个已批准问题及量表，共 24 个问题。页面、API、数据库和评分引擎均已接入现有 TenderTrace 服务，数据库升级到版本 58。

系统评分由事实准确、证据引用、风险意识、行动完整和表达清晰五个确定性维度组成。同一回答、同一证据和同一评分版本可以稳定复算；模型只能提交表达评价候选，不改变规则总分。模型置信度低或与规则分差过大时，结果进入人工复核。训练数据只写入五张训练表，生产验收和运行冒烟均证明正式公告、需求与修订表没有被训练过程修改。

自动验收使用 5 份人工批准的脱敏前后测文本验证评分稳定性：平均分从 54 提升到 98，复算全部一致，正式项目哈希保持不变。这 5 份文本是评分基准样本，不是真人学习实验；当前真人参与人数为 0。因此，本报告确认“系统具备组织同量表前后测的能力”，不宣称已经证明真实学习效果。比赛前仍须由至少 5 名真实成员完成前后测，才可验收方案中的真人效果指标。

核心指标	当前结果	验收解释
已批准训练场景	4	覆盖 4 种场景类型
真实脱敏项目	4	高于至少 3 个项目要求
已批准问题/量表	24	每场景 6 个阶段
评分维度	5	确定性规则评分
基准文本样本	5 组前后测	仅验证评分与比较链路
基准平均分	54 → 98	提升 44 分，不等同真人效果
正式项目写入	0 次	训练与正式业务隔离
全量回归	564/564	另有 616 个子测试通过
训练目录响应	19.2 ms	本机运行态实测

二、与已有提升方向的融合

2.1 与方向一“投标数字孪生”的融合

训练场景读取项目档案中的公告事实、地区、采购方和来源链接，用真实项目上下文替代通用题库。训练结束后不会改写项目阶段、认领状态或投标结论。

2.2 与方向二“可审计证据链”的融合

每道题保存允许使用的证据 ID。参训者必须主动勾选公告、要求或修订证据，评分器分别计算“说对事实”和“引用证据”，避免只凭流畅表达得到高分。证据入口保留原始来源地址，页面不会把未批准材料混入本轮训练。

2.3 与方向三 “变更影响引擎” 的融合

更正公告应急场景复用真实公告修订。系统可以追问截止时间、需求或风险如何变化，但模拟回答和假设变化只存在训练对象中，不回写正式修订、影响判断或项目任务。

2.4 与方向六、七 “多角色会审与决策沙盘” 的融合

训练角色覆盖主讲人、项目负责人、投标经理、技术负责人、法务、销售和合作负责人。它复用“事实与判断分开、低置信度转人工、证据不足不下结论”的会审原则，但不代替正式会审或投标决策。

2.5 与方向八 “飞书投标战情室” 的融合

评分低于阈值会生成补强任务。用户明确点击后，可把单项任务同步到飞书；同步保存任务回执并支持幂等复用。系统不会在训练完成时自动向外发送消息。

2.6 与方向九 “企业投标记忆体” 的融合

历史训练结果可按本人查看和回放；团队管理视图只显示聚合人数、完成场次、维度均值和共同薄弱点。训练结果标注“不可作为绩效结论”，自动基准文本也不进入团队真人准备度。

2.7 与方向十三、十六的融合

评委现场挑战可以转成七分钟脱稿答辩训练；合作方尽调中的风险与缺口可以转成谈判追问。训练中心只读取经批准事实，不替代现场挑战结果或合作方尽调结论。

三、十个实施步骤及逐项验收

3.1 第一步：建立独立训练数据模型

数据库版本升级到 58，新增五张表：

数据对象	作用
training_scenarios	场景类型、角色、真实项目快照、批准状态和边界
training_sessions	参与者、模式、难度、当前阶段、计时和隐私信息
training_turns	首次回答、证据引用、追问、规则得分和模型候选
training_rubrics	每道题的能力点、事实、允许证据、评分和停止条件
training_results	五维得分、总分、版本、回放、补强任务和复算哈希

五张表与正式项目表分离，并建立场景项目、会话参与者、轮次和结果分数索引。数据库健康接口已经显示版本 58 和全部训练表。

3.2 第二步：从真实项目建立批准场景

生产种子脚本选择 4 个已有真实公告，以脱敏名称建立训练场景。每个场景都保存真实公告 ID、来源 URL、地区、采购方、正文摘录、需求和最新修订，并明确 `real_notice=true`、`anonymized_for_training=true`。

场景	脱敏项目	主要角色	问题数
七分钟脱稿答辩	北京·服务器项目	主讲人、项目负责人、管理者	6
技术标澄清	全国·服务器项目	技术负责人、投标经理、交付负责人	6
更正公告应急	全国·采购项目	投标经理、法务、项目负责人	6
合作方风险谈判	四川省·服务器项目	销售、法务、合作负责人	6

3.3 第三步：实现六阶段确定状态机

训练流程固定为：

> 开场 → 基础事实 → 证据追问 → 风险变化 → 行动计划 → 总结。

状态机决定当前阶段、问题序号、是否继续追问以及何时结束。语言模型不能跳阶段、直接结束训练或修改评分规则。若回答出现“百分之百、完全满足、肯定、没有风险、已经影响”等绝对表述但没有引用允许证据，系统先插入一次证据追问，再进入下一阶段。

3.4 第四步：为每道题固化训练契约

每道题保存能力点、参考事实、允许证据、多维评分规则、追问条件和停止条件。场景只有在批准状态下才能创建会话。当前 4 个场景共 24 道批准题目，覆盖陈述、事实核验、证据引用、变化响应、行动闭环和总结表达。

3.5 第五步：提供学习与准备双模式

准备模式用于比赛模拟：提交前不显示完整参考答案，首次回答保存后不可被后续修改覆盖。学习模式允许逐层索取提示，并可打开批准证据。两种模式使用相同题目和评分版本，可以进行可比的前后测。

难度支持引导、标准和压力三档。第一版只调整追问压力和提示，不改变核心评分标准，避免同一能力因难度档位而失去可比性。

3.6 第六步：建立确定性多维评分

最终总分由固定规则计算：

- 事实准确：是否覆盖批准事实且没有无依据断言；
- 证据引用：是否引用本题允许证据；
- 风险意识：是否说明未知项、缺口和结论边界；
- 行动完整：是否给出负责人、核验或后续闭环动作；
- 表达清晰：是否先给结论、结构完整且易于现场理解。

评分结果保存版本 `training-rubric-v1` 和得分哈希。同一输入复算返回 `identical=true`。评分版本升级时可以保留旧结果并重新计算，防止历史数据被静默覆盖。

3.7 第七步：限制模型评价权限

模型可以输出表达评价分、置信度和理由，但它只是候选意见。置信度低于 80，或模型分与规则分差超过 25 分时，状态变为 pending_review。模型分始终标记 score_affects_result=false，不改变确定性总分。

准备模式不会把模型理由变成标准答案泄露给参训者。界面报告同时展示模型状态和规则评分，使评委可以区分机器建议与最终可复算结果。

3.8 第八步：隔离训练与正式项目

训练场景读取真实项目快照；模拟变化、回答、追问、评分和任务草稿只写训练表。生产评估在训练前后计算公告、需求和修订表哈希，结果完全一致。运行态完整六轮冒烟报告 formal_project_write_count=0。

任何补强任务只有用户主动点击“同步飞书任务”后才调用飞书接口。这个动作不会修改公告、机会状态、会审意见、能力确认或合作方结论。

3.9 第九步：匿名回放与团队准备度

个人可以查看完整回放，包括每轮问题、首次回答、证据、规则分、追问和耗时。普通参与者只能读取自己的会话；其他参与者密钥访问会返回无记录。管理视图只聚合参与人数、完成场次、五维均值和共同薄弱点。

自动基准样本使用 approved_transcript 类型，明确排除在真人团队统计之外。本次运行冒烟结束后团队参与人数仍为 0，证明基准样本不会虚增真人准备度。

3.10 第十步：建立评委友好的训练指挥舱

主导航新增“训练中心”。页面采用三栏布局：左侧选择真实场景、角色、模式和难度；中间显示六阶段、问题、计时、回答、证据选择和五维报告；右侧显示允许证据、模式规则和模型边界。下方展示团队共同薄弱点与个人历史。

页面支持 1250、900 和 560 像素响应式断点，投屏模式会放大核心训练区域；系统关闭动效或启用 prefers-reduced-motion 时，回答、证据和回放仍然可用。切换场景会清理旧会话和计时，避免新场景显示上一场训练结果。

四、评委现场演示路径

推荐使用“七分钟脱稿答辩”场景进行 90 秒演示：

1. 打开训练中心，指出页面显示“真实项目、状态机、规则评分、个人结果”四条可信边界；
2. 选择“七分钟脱稿答辩”、主讲人、准备模式和标准难度；
3. 点击建立会话并开始，展示六阶段状态机和现场计时；
4. 首轮故意回答“我们完全满足要求，没有风险”，且不选证据；
5. 展示系统没有直接给高分，而是触发证据追问；
6. 第二轮引用 NOTICE: 证据，并说明“当前证据只能支持项目存在，资格和风险仍需核验”；
7. 连续完成六阶段，打开五维得分、薄弱点和补强任务；
8. 展开匿名回放，查看首次回答、证据、规则分和评分版本；
9. 点击重新复算，展示结果一致；

10. 指出正式项目写入为 0，并说明补强任务只有手动确认才同步飞书。

这条路径同时展示“会追问、讲证据、能评分、可复算、不污染正式项目、能形成行动”六个比赛亮点。

五、API 与数据链路

主要 API：

- POST /api/training/scenarios/seed：从真实项目建立或更新批准场景；
- GET /api/training/scenarios：读取训练目录、类型、项目数和规则；
- GET /api/training/scenarios/{scenario_id}：读取单个场景和允许证据；
- POST /api/training/sessions：创建模式、角色、难度明确的会话；
- POST /api/training/sessions/{session_id}/begin：开始计时和状态机；
- POST /api/training/sessions/{session_id}/hint：学习模式获取分层提示；
- POST /api/training/sessions/{session_id}/answer：保存首次回答、证据和评分；
- GET /api/training/sessions/{session_id}：按参与者权限读取会话或回放；
- GET /api/training/sessions：读取个人历史；
- GET /api/training/team-readiness：读取去标识团队聚合；
- POST /api/training/results/{result_id}/recompute：按原版本复算；
- POST /api/training/results/{result_id}/tasks/{task_id}/sync-feishu：手动同步补强任务。

完整数据链路：

> 真实公告/需求/修订 → 批准脱敏场景 → 六阶段会话 → 首次回答与证据 → 确定性五维评分 → 模型表达候选 → 低置信度人工复核 → 匿名回放 → 补强任务 → 可选飞书同步。

六、自动验收结果

6.1 方向十八专项测试

tests/test_scenario_training.py 共 5 项测试全部通过：

测试	结果
版本 58、五张训练表、至少 3 个真实项目、4 类场景和 24 量表	通过
状态机、学习提示、无证据绝对表述追问、复算和正式表不变	通过
准备模式隐藏答案、首次回答保存、低置信度模型转人工	通过
个人隔离、团队聚合、飞书任务幂等回执	通过
场景、会话、答题、历史和团队 API	通过

专项 Python 测试结果为 5 passed。前端新增训练中心契约，检查六阶段、两种模式、正式项目隔离、API、五维报告、完整回放、场景切换清理、响应式断点和减少动效。

6.2 组合回归

方向十八与现场挑战、决策沙盘、变更影响、合作方尽调、战情图和公共前端的组合测试结果为：

45 passed, 4 subtests passed。

这组测试验证新训练模块复用已有数据和证据时，没有改变上述模块的判断与写入行为。

6.3 全量回归

执行：

```
.venv\Scripts\python.exe -m pytest -q
```

结果：564 passed, 616 subtests passed，耗时 187.47 秒。唯一警告为 FastAPI/Starlette TestClient 对旧版 httpx 兼容层的上游弃用提醒，不影响当前服务运行。

同时通过：

```
.venv\Scripts\python.exe -m ruff check tendertrace/scenario_training.py tendertrace/db.py
tendertrace/app/api.py tests/test_scenario_training.py tests/test_battle_map.py tests/test_web_static.py
scripts/seed_scenario_training_demo.py scripts/evaluate_scenario_training.py
node --check web/dist/app.js
node --test scripts/test_workbench.cjs
```

结果：Ruff 通过；JavaScript 语法通过；工作台 7/7 通过。

七、生产运行态验收

服务重启后，真实 HTTP 检查结果如下：

检查项	结果
/api/health	status=ok
数据库版本	58
场景数 / 项目数 / 类型数	4 / 4 / 4
训练页面	HTTP 200, 107,312 字节
页面训练容器	存在 trainingView
完整状态机	6 轮后完成
运行样本得分	76, 版本 training-rubric-v1
评分复算	identical=true
正式项目写入	0 次
训练目录响应	19.2 ms
真人团队人数	0, 基准样本未计入

内置浏览器自动控制组件在验收时出现本机运行资源路径缺失，无法建立自动视觉检查连接。这是 Codex 浏览器控制环境问题，不是 TenderTrace 站点连接失败。页面已经通过真实 HTTP、API、DOM 契约、JS 语法、响应式布局和减少动效测试，并已在 Codex 浏览器排入演示地址；本报告不把未执行的自动截图检查写成通过。

八、前后测证据与正确解释

评估脚本生成 5 组人工批准的脱敏答题文本，每组使用同一场景、同一量表和同一评分版本完成“较弱回答”和“补强回答”比较。

样本	前测	后测	差值	前后复算
样本 01	54	98	+44	一致
样本 02	54	98	+44	一致
样本 03	54	98	+44	一致
样本 04	54	98	+44	一致
样本 05	54	98	+44	一致

这些结果证明：评分器能区分证据、风险边界和行动完整度不同的回答；同样本可复算；系统能保存同口径前后测。它们不能证明 5 名真实人员通过训练获得了 44 分提升。

真实效果验收方案：

1. 招募至少 5 名比赛相关成员并取得参与同意；

- 2. 固定同一场景、角色、难度、量表和评分版本；
- 3. 先在准备模式完成前测；
- 4. 允许学习模式查看分层提示和批准证据；
- 5. 间隔固定时间后完成后测；
- 6. 公开样本量、缺席、异常、中位数、均值和个体差异；
- 7. 人工抽查绝对表述、证据引用和行动闭环；
- 8. 把结果标为内部小样本，不外推为普遍学习效果。

九、数据安全、隐私与权限边界

- 场景使用脱敏项目别名，来源证据仍可由授权用户核查；
- 个人会话按参与者密钥隔离，普通参与者不能读取他人完整答案；
- 团队视图只展示聚合结果，并明确不可作为绩效判断；
- 自动基准文本不计入团队真人统计；
- 模型评价不改变确定性规则分；
- 低置信度或规则冲突进入人工复核；
- 模拟变化和答案不写回正式公告、修订、要求、决策、能力或尽调；
- 飞书补强任务必须由用户主动触发，且保存回执和幂等状态。

十、本地环境与可运行性

项目	验收环境
操作系统	Windows 10 专业版 10.0.19045
CPU	AMD Ryzen 9 5900HX, 16 逻辑处理器
内存	15.4 GB
Python	3.12.14
Node.js	v24.19.0
PowerShell	7.6.5
服务地址	http://127.0.0.1:8000/
训练入口	http://127.0.0.1:8000/?view=trainingView

服务已通过计划任务重启，主服务与飞书长连接监听任务均成功启动。健康接口返回 ok，飞书应用、消息、表格和任务同步配置均处于已配置状态；方向十八只在用户主动同步补强任务时使用飞书写入能力。

十一、未完成项、限制与后续措施

11.1 真实 5 人前后测仍待执行

这是当前唯一未完成的方案验收项。原因不是系统缺少功能，而是当前没有 5 名真实成员参加正式训练。应在比赛前按第八节方案组织实测，并把结果追加到本报告；完成前不得对外宣称已经证明真实学习效果。

11.2 语音模式暂不启用

第一版坚持文字优先。现场语音会受到麦克风、回声、网络和识别延迟影响。只有在指定比赛硬件上完成识别准确率、延迟、断网降级和隐私验证后，才应增加语音输入；当前页面不把浏览器语音能力包装成已完成产品。

11.3 模型只负责表达候选

当前本地模型增强关闭，系统仍能完整训练和评分。后续启用模型时，也应保留规则总分、候选理由、置信度和人工复核四项，不应把模型自由评价升级为不可解释的最终分。

11.4 场景治理需要持续执行

公告失效、项目规则变化或量表修改后，应生成新场景版本并重新批准。旧结果保留原评分版本，不应直接覆盖。建议赛前由投标经理、技术负责人和法务各审一次对应题库。

11.5 浏览器自动视觉工具待环境修复

内置浏览器控制组件的本机资源路径需要修复。修复后应补跑 1440×900、1920×1080、900×700 和 560×800 四个视口，记录关键溢出、按钮可见性、字体大小和完整训练路径截图。当前响应式与降级逻辑已通过静态契约测试，但不能替代这项人工或浏览器截图复核。

十二、交付物清单

交付物	路径
训练与评分引擎	tendertrace/scenario_training.py
数据库升级	tendertrace/db.py
API 集成	tendertrace/app/api.py
训练中心页面	web/dist/index.html
页面交互	web/dist/app.js
视觉样式	web/dist/styles.css
专项测试	tests/test_scenario_training.py
前端契约测试	tests/test_web_static.py、scripts/test_workbench.cjs
生产场景脚本	scripts/seed_scenario_training_demo.py

交付物	路径
自动验收脚本	scripts/evaluate_scenario_training.py
场景证据	docs/demo/scenario_training_live_demo_20260929.json
验收证据	docs/demo/scenario_training_acceptance_20260929.json
本独立报告	docs/roadshow/提升方向十八_情景训练与智能问答演练中心优化进度与验收报告-20260929.md

十三、最终验收判定

方向十八的软件建设、集成、运行与回归验收通过：4 个真实脱敏项目、4 类批准场景、24 道批准问题、六阶段状态机、双模式、确定性多维评分、模型复核边界、正式项目隔离、匿名回放、补强任务、可选飞书同步和评委友好界面均已落成并可运行。

方向十八的“至少 5 名真实成员前后测”属于赛前团队活动，当前状态为待执行。系统没有用 5 份基准文本冒充真人效果。完成该活动并追加真实样本统计后，本方向的产品能力和真人效果证据才同时闭环。

验收结论

方向十八核心软件已完成并通过验收；真实 5 人前后测待赛前执行。